Makaled Consulting Group

Integrantes
Eduardo Villalobos Sánchez - Data Analyst
Alejandro Apuy Anchía - BI Engineer
Marilyn Miranda Jaen - Data Analyst
Katherine Rojas Saborío - Business Translator

Contexto del Negocio

La industria que el proyecto abordará serán las áreas de E-Commerce y ventas, de una empresa con 60,000 mil registros.

La empresa Shopify es un E-Commerce B2C minorista con una base de clientes distribuida a través de todo el mundo en diferentes regiones y países. Es una empresa con un volumen de transacciones medio-alto ofreciendo una gran gama de productos clasificables en diferentes áreas, lo que permite canalizar diferentes nichos de mercado y aumentar el valor de cada carrito mediante la presentación de las diferentes categorías para el cliente.

Planteamiento del Problema

La tienda de Shopify, aunque ha sido rentable a lo largo del tiempo, ha experimentado una tasa de devoluciones de aproximadamente 14%, mantenida durante los últimos 3 años, esto afecta directamente costos de envíos y logística global; sin embargo, no ha logrado identificar patrones de compra que expliquen la causa de estas devoluciones.

Objetivos del proyecto

- Proveer un diagnóstico y perfilamiento de datos que habilite a la gerencia a tomar decisiones para reducir la tasa global de devoluciones en al menos un 7% durante el siguiente semestre.
- Determinar el perfil de los clientes propensos a realizar al menos el 40% de devoluciones, con el fin de generar estrategias para retener las compras de este segmento.
- Identificar estrategias que reduzcan en al menos un 10% el costo de los envíos que resultan afectados por el volumen de devoluciones.

Data Sourcing

Fuente principal del proyecto es un dataset de Kaggle de la empresa Shopify, es un CSV de 60000 filas y 17 columnas, cada fila representa una compra identificada por “order_id”, No hemos logrado definir si el dataset es de dominio público o son datos inventados. Otro aspecto importante es la antigüedad de la información.

Los datos son antiguos y corresponden a un periodo cerrado, por lo que no habrá un proceso automatizado de actualización ni conexión directa con la tienda. La carga del archivo se hará de forma manual, una sola vez, y se trabajará sobre una copia para conservar intacto el original. Esto tiene una ventaja práctica, porque garantiza que los resultados sean reproducibles al partir siempre del mismo punto de partida, aunque también implica que las conclusiones describen lo que ocurrió en ese periodo y no necesariamente lo que ocurre hoy en el negocio.

Identificación de KPIs

1. Tasa de Devolución por Categoría de Producto y SKU

Fórmula: $Tasa_{g} = \frac{Pedidos\ devueltos_{g}}{Pedidos\ totales_{g}} \times 100$

Donde ***g*** es ***product_category*** (usado como variante para el SKU).

Este KPI nos permitirá identificar qué categorías están teniendo una tasa de retorno mucho más alta en comparación a las demás, lo que a su vez nos habilita el insight de que productos podrían tener defectos de calidad, descripciones engañosas, o problemas del proveedor directamente.

2. Tasa de Devolución Mensual y Semestral

Fórmula: $Tasa_{t} = \frac{Pedidos\ devueltos\ con\ order_date \in t}{Pedidos\ totales\ con\ order_date \in t} \times 100$

Donde **t** es ***mes o semestre .***

Este KPI nos permitirá mostrar la tendencia y estacionalidad (Dígase Black Friday, Rebajas de Otoño, etc.) Brindando una visión mensual con picos y problemas puntuales que nos acerca a conocer si tuvimos un lote defectuoso o una campaña de descuento mal ejecutada, y el semestral habilitando reportes ejecutivos y definición de metas.

3. Ratio de Frecuencia de Devolución por Cliente

$$Ratio_c = \frac{Pedidos\ devueltos\ por\ el\ cliente\ c}{Pedidos\ totales\ del\ cliente\ c}$$

$$Porcentaje\ de\ clientes\ que\ devuelven = \frac{Clientes > 1\ devolución}{Clientes\ totales} \times 100$$

Donde ***C*** se atribuye al cliente.

Este KPI nos permite distinguir entre un problema de producto y un problema de comportamiento, ya que si se reparten entre muchos clientes el origen puede estar ubicado entre el producto o proceso, y si se concentra en pocos clientes puede estar relacionado a un patrón abusivo de comportamiento (Dando posibilidad de analizar fraudes o la aplicación de ***Wardrobing***).

4. Índice de Gravedad del Comprador

$$Índice\ de\ Gravedad_c = w_1 \times Frecuencia\ Normal + w_2 \times Valor\ Devuelto\ Normal + w_3 \times Impacto\ al\ Profit\ Normal$$

Donde: (C equivale a cliente

- W1: Peso de la frecuencia de devolución.
- W2: Peso del valor devuelto.
- W3: Peso del impacto en el profit.

$$Frecuencia_c = \frac{Pedidos\ Devueltos_c}{Pedidos\ Totales_c}$$

$$Valor\ Devuelto_c = \frac{Revenue\ Pedidos\ Devueltos_c}{Revenue\ Total_c}$$

$$Impacto\ al\ Profit_c = \frac{Profit\ Pedidos\ Devueltos_c}{Profit\ Total_c}$$

Este último KPI nos permitirá identificar qué impacto tiene un cliente al momento de realizar una devolución, variando entre clientes que compren artículos con un valor alto y artículos más baratos. Esto nos habilita la revisión de posibles fraudes de igual manera, y evitar penalizar a clientes que realmente hayan tenido problemas con el producto.

Arquitectura y Tratamiento de Datos

Diccionario de Datos Final

Este diccionario permite informar acerca de los datos utilizados para el análisis mediante un lenguaje de fácil comprensión.

Columna	Significado	Tipo de dato	¿Qué representa el dato?
order_id	Identificador del pedido	Numérico (código)	Número de orden que identifica cada pedido y permite unir las tablas.
order_date	Fecha del pedido	Fecha	Día en que el cliente hizo la compra.
customer_id	Identificador del cliente	Numérico (código)	Código que identifica a cada cliente. Se alinea con el objetivo de identificación de clientes que realizan el 40% de devoluciones.
product_id	Identificador del producto	Numérico (código)	Código que identifica a cada producto vendido.
product_category	Categoría del producto	Categórico	Categoría al que pertenece un producto.
product_price	Precio del producto	Numérico	Precio del producto, antes de aplicar descuentos.
discount_percent	Porcentaje de descuento	Numérico	Descuento aplicado a la compra, expresado en porcentaje.
quantity	Cantidad	Numérico	Número de unidades compradas en el pedido.
payment_method	Método de pago	Categórico	Método de pago del consumidor al realizar el pedido. Se mantiene, ya que permite segmentar a los consumidores.
customer_country	País del cliente	Categórico	País al que pertenece o se envió el pedido del cliente.
shipping_cost	Costo de envío	Numérico	Costo de enviar el pedido al cliente. Se alinea para conocer las pérdidas de dinero como consecuencia de las devoluciones.
rating	Calificación	Numérico	Puntuación que el cliente dio a su compra.

is_returned	¿Fue devuelto?	Categórico (Sí / No)	Indica si el pedido fue devuelto (Sí) o (No).
discounted_price	Precio con descuento	Numérico	Precio de una unidad después de aplicar el descuento.
revenue	Ingresos	Numérico	Dinero que genera el pedido por la venta.
profit	Ganancia	Numérico	Dinero que realmente queda después de descontar los costos.
return_date	Fecha de devolución	Fecha	Día en que se devolvió el pedido. Solo existe si hubo devolución.
return_reason	Motivo de devolución	Categórico	Razón por la que el cliente devolvió el producto, contiene 10 motivos importantes que se pueden categorizar.
refund_status	Estado del reembolso	Categórico	Situación del reembolso al cliente, ya sea reembolsado, no reembolsado, pendiente, rechazado, reembolso con crédito o desconocido. Permite realizar cálculos para comprender los costos de las devoluciones.
order_month	Mes del pedido	Categórico	Mes en que se hizo el pedido mostrado como texto, con el fin de identificar tendencias.
order_day	Día de la semana del pedido	Categórico	Día de la semana en que se hizo el pedido (lunes, martes…).
return_days	Días hasta la devolución	Numérico	Días que pasaron entre la compra y la devolución.

Modelo de Datos final

Se creó una nueva tabla con la información de las **devoluciones**, donde se incluyen datos como el número de orden, la fecha de devolución, el motivo y el estado del reembolso.

Luego, esta tabla se unió con la tabla principal utilizando el campo **order_id,** ya que este dato permite relacionar cada devolución con su pedido correspondiente.

Para realizar la unión se utilizó un Left Join, con el propósito de mantener todos los registros de la tabla principal y agregar la información de las devoluciones cuando exista una coincidencia. Si un pedido no tiene una devolución asociada, se conserva igualmente en la tabla y los campos relacionados con la devolución quedan vacíos.

De esta manera, se obtiene una tabla final más completa, que reúne en un solo lugar la información de los pedidos y sus posibles devoluciones. Esto facilita el análisis de los datos y permite identificar de forma sencilla cuáles pedidos fueron devueltos, el motivo de la devolución y el estado del reembolso.

Reglas de Limpieza y Transformación (Data Lineage)

Para la transformación de los datos y la tabla, se realizaron los siguientes cambios:

- Los campos **order_date** y **return_date**, se convirtieron a formato de fecha y hora (datetime64).
- El campo **is_returned** se convirtió de tipo númerico a verdadero/falso (Booleano) ya que solo presentaba valores de 0 y 1.
- Se creó un nuevo campo llamado **order_month** para tener la trazabilidad del mes del pedido.
- Se creó un nuevo campo llamado **order_day** para tener la trazabilidad del día del pedido.
- Se creó un nuevo campo llamado **return_days** comparando la diferencia de días entre la fecha de devolución y la fecha del pedido
- En el campo de **return_reason**, se rellenó con “NA”, evitando contener datos nulos en pedidos que no fueron devueltos.
- En el campo de **refund_status** se rellenó de igual forma con “NA” evitando contener datos nulos en pedidos válidos.
- Se eliminaron por completo la columna de **traffic_source**, ya que esta no es necesaria en el contexto del análisis que se trabajará.
- Se recalculó el campo revenue y el campo de profit para reflejar los costos operativos reales, ya que no se estaban tomando en cuenta los importes operativos de la empresa basados en datos del equipo usando el costo de

producto (COGS), marketing, comisiones de pasarela de pago, plataforma y personal empleado durante todo el ciclo de vida de la transacción.

Los outliers identificados en las columnas de ***revenue*** y ***profit*** no fueron eliminados de los datos finales debido a que se detectó que no son errores o anomalías en el dataset final, sino corresponden a un patrón de compras específico que contiene los siguientes puntos clave:

- Volumen de compra elevado: Estas transacciones atípicas incluyen el máximo o cercano al máximo de unidades permitidas por compra (4 o 5 unidades)
- Precios unitarios altos: Son productos que se encuentran dentro de los clasificados como más “caros” variando desde $600 a 800 por unidad.
- Descuentos no significativos: Las órdenes que generan estos outliers cuentan con un porcentaje de descuento muy reducido (5% aproximadamente) lo que genera un valor total más alto en comparación a otras órdenes.

Por las anteriores, se decide que los outliers son datos válidos y no tienen que ser eliminados del dataset, ya que hacerlo estaría modificando de manera totalmente incoherente la autenticidad del análisis.

Exploratory Data Analysis (EDA)

Patrones iniciales

La exploración inicial de estos datos nos permitirá identificar comportamientos históricos, distribución de ingresos y las dinámicas operativas de la plataforma en un periodo comprendido de los años 2023 al 2025.

Iniciando con un análisis univariado de datos, podemos denotar que el grueso del negocio se encuentra principalmente en las transacciones con un importe menor a los $800, haciendo especial hincapié entre los $150 y los $500.

Esto nos permite identificar que contamos con un sesgo positivo pronunciado, dominado por una alta frecuencia en las compras de tickets bajos y medios, aunque acompañados por su parte de una cola de tamaño considerable en transacciones mayores cuyos valores alcanzan los $4000, lo que nos indica que la operación principal sigue descansando sobre las compras de menor importe unitario.

En cuanto a antigüedad y comportamiento de los clientes, se puede observar un flujo constante de transacciones tanto de clientes nuevos como recurrentes, sin que exista un nicho específico que desequilibre la base de compras a nivel global.

La distribución temporal de las devoluciones en este caso nos refleja que todas estas transacciones se realizaron de forma homogénea en un largo de 2 a 30 días, con un promedio específico apuntado a los 16 días evidenciando que puede estar relacionado más a las características per se del producto o expectativas sobre el mismo que técnicas como wardrobing.

Tendencias

Mediante el análisis exploratorio inicial es posible detectar que no existe una tendencia al alza o baja en la mayoría de las variables. A lo largo del tiempo observado, las órdenes se mantienen entre aproximadamente 1800 y 2150, sin crecimientos ni caídas sostenidas. Asimismo, las devoluciones, que corresponden a la variable principal observada para el proyecto, mantienen una línea sostenida a lo largo del tiempo, la cual presenta un valor entre aproximadamente 13.50% y 16.50%; sin embargo, existe una subida en meses como febrero y marzo del 2023. La línea que marca el fin en una tendencia hacia la baja en devoluciones se presenta en el último mes, lo cual se justifica al tomar en cuenta la discrepancia entre fechas de registro de la última orden y la última devolución.

Por otra parte, los ingresos presentan subidas y bajadas a lo largo del tiempo, apuntando a una bajada desde octubre del 2024 a febrero del 2025, pero sin picos altamente significativos.

Un hallazgo importante es que tampoco se encuentran tendencias en los días hasta la devolución, ya que todas las devoluciones registradas se mantienen entre los 2 y 30 días después de la compra, distribuidas de manera uniforme a lo largo de los datos. Verificando la dispersión del porcentaje de descuento, el precio de los productos y el costo de envío, se aprecia que estas variables tampoco explican las devoluciones, pero de forma puntual, la tasa de devolución más alta se presenta con un descuento mayor (40%), un precio que supera los 700 USD. Los descuentos más bajos, junto con el costo de envío más bajo, representan pocas devoluciones.

Anomalías

Al revisar los gráficos del EDA se identificaron patrones que no son consistentes con el comportamiento esperado de un e-commerce real. Estos hallazgos se basan en la lectura de los gráficos y deben validarse contra el csv antes de tomar decisiones de negocio.

1. **Ingresos concentrados en un máximo teórico**. Los outliers de revenue se agrupan alrededor de 4000. Ese valor corresponde al precio máximo sin descuento. Aunque se justifica en el documento como compras validas, que

tantos pedidos caigan justo en ese tope indica que los valores se generan combinando variables independientes, no que reflejan un patrón de compra real.

2. **Precios y costos de envío sin relación realista**. El precio del producto sigue una distribución uniforme entre $5 y $800, y el costo de envío oscila entre $2 y $25 lo que representa cerca de 2-3% del precio y queda aplastado en el boxplot. Ninguna de las 2 variables muestra la asimetría típica de un catálogo real.
3. **Descuentos sin el valor de 35%**. Los niveles de descuentos observados escalan de 5 en 5 hasta llegar a 40 pero la ausencia del 35% sugiere que se tomaron de una lista fija y no de un rango continuo.
4. **Ausencia de estacionalidad**. Las órdenes se mantienen entre 1800 y 2000 al mes, sin picos en noviembre o diciembre ni caídas en enero. Un comportamiento inusual para ecommerce y limita el análisis de fechas fuertes como el black friday.
5. **Junio 2025 incompleto**. Los datos terminan el 18 de junio del 2025, la caída visible en la última barra mensual y en la última semana corresponde a un periodo parcial y no debe interpretarse como una disminución real de ventas.

Variables de mayor impacto para el negocio

Las variables de mayor impacto en el negocio son las devoluciones, los ingresos y las ganancias, porque están directamente relacionadas con el rendimiento económico de la empresa.

- Devoluciones: muestra cuántos pedidos fueron devueltos.
- Ingresos: muestra el dinero generado por las ventas.
- Ganancias: muestra el dinero que queda después de descontar los costos.

Los ingresos representan el dinero que se genera con las ventas realizadas, mientras que las ganancias permiten conocer cuánto dinero realmente queda después de descontar los costos.

Las devoluciones también tienen un impacto importante, ya que cuando un cliente devuelve un producto, la empresa puede tener gastos adicionales relacionados con el envío y la logística. En este proyecto, la tasa de devoluciones es aproximadamente del 14%, por lo que representa un aspecto importante de análisis.

Al analizar estas tres variables en conjunto se puede observar cuánto dinero genera la empresa, cuánto realmente gana y de qué manera las devoluciones pueden estar afectando estos resultados. Esto ayuda a identificar posibles pérdidas y a buscar formas de reducir las devoluciones para mejorar la rentabilidad del negocio.

Visualización y Hallazgos Clave del Dashboard

El dashboard está estructurado en tres vistas navegables mediante un panel de filtrado lateral, con filtros globales como País, Categoría de Producto y Fecha de Actualización.

Vista Estratégica: Está evalúa la salud financiera global de la tienda, la magnitud del impacto en las devoluciones realizadas, y el efecto que tienen los descuentos sobre la rentabilidad.

En cuanto a la visión general financiera, en la primera pestaña de nuestro dashboard podemos encontrar una monitorización de volumen total de ingresos ($59.65M), rentabilidad neta ($24.75M) e impacto directo de las devoluciones (14.72%) mediante los componentes KPI, y también podemos encontrar gráficos de ingresos agrupado por categorías, tendencia semestral de ventas y pérdidas por devolución, y el efecto del porcentaje de descuento sobre el márgen operativo.

Vista Táctica: Esta identifica o descarta concentración de devoluciones según variables geográficas, métodos de pago, categorías de productos, y evalúa la ventana temporal de devolución.

En la segunda pestaña, encontramos componentes para indicar la frecuencia de devoluciones hechas por los clientes (2,72%), tasas mensuales de devolución (14,81%) y también un estimado del tiempo de retorno de los pedidos (15.96%). Este segmento nos demuestra también mediante gráficos las mayores zonas de devolución a nivel mundial, cuáles categorías de estos productos representan la mayoría de devoluciones y también bajo cuál método de pago sucede.

Vista Operativa: Esta diagnostica las causas raíz de las devoluciones, clasifica el comportamiento recurrente en la base de clientes, y cuantifica la afectación logística.

Para finalizar, el último segmento del dashboard nos muestra gráficos como el de distribución de costos de envío (14% por categoría aprox), desglose de motivos de devolución en los pedidos (Tallas, Productos Defectuosos, etc.) y un gráfico de clasificación cualitativa para medir nuestros clientes según su nivel de insatisfacción.

Insights de Alto Valor Vinculados a las Metas

Primera Meta (Identificar causas que ayuden a reducir la tasa global de devoluciones en el próximo semestre)

Diagnóstico de estabilidad y causa concentrada: La tasa de devolución se ha mantenido en un perfil constante entre los 14.81% mensual, lo que se traduce a un 14.72% del ingreso total generando pérdidas aproximadas de unos $1.7 Millones semestrales. Mediante el análisis del EDA podemos descartar que el problema recaiga en una sola categoría, país o medio de pago específico, ya que los 7 segmentos operan en un rango uniforme con variaciones menores al 15%

Fallas Internas como detonante: Encontramos que aproximadamente una tercera parte (33%) de todas las devoluciones responden a productos defectuosos y tallas equivocadas, sumado a esto, si agregamos otras causas como “No es como se describe el producto” o “calidad no esperada” subimos a un 62% total de las causas de devolución, indicando que este porcentaje son temas ajenos a la empresa per se, y dependen más de controles de producto, catálogo y proveedores.

Corregir estas inconsistencias puede permitirnos alcanzar e incluso superar la meta de reducir dicha tasa de devoluciones a un 7% o menos.

Segunda Meta (Determinar el perfil de clientes que son menos propensos a realizar devoluciones y retenerlos)

Comportamiento y tiempo del consumidor: Este análisis demuestra que el cliente toma (en promedio) 16 días en realizar una devolución, distribuido entre las distintas categorías de manera homogénea (De 15.8 a 16.1 días). Esto nos permite de manera inmediata descartar la hipótesis de una práctica de wardrobing masivo, y abre una ventana de oportunidad preventiva durante 14 días para garantizar mediante el contacto con los clientes que el pedido haya cumplido las expectativas.

Segmentación del riesgo: De todos los clientes que presentan devoluciones, un 59% aproximadamente corresponde a compradores que resultaron “insatisfechos” con su producto (Unos 4950 usuarios), mientras que sólo un 14% (437 clientes) pueden ser puestos en la categoría “tóxicos”. Estos últimos presentan patrones que desgastan progresivamente las utilidades de la empresa.

Este análisis a profundidad representa una de las mayores oportunidades para averigüar qué acciones pueden ser aplicadas para sesgar notoriamente esta tasa de devoluciones.

Tercera Meta (Reducir al menos un 10% el costo de envíos afectados por las devoluciones)

Ineficiencia en gasto logístico: Los costos de envío generados por productos que han sido devueltos se encuentran alrededor de los $60,000 globales,

este gasto es distribuido equitativamente entre todas las categorías (Unos $8,600 cada categoría).

Resolver estos errores de embalaje, daños en tránsito y atrasos en entregas reduciría aproximadamente unos 1300 casos de devoluciones, además, un ajuste a la política de devoluciones (en casos voluntarios por cambio de opinión) en cuanto a temas de asunción de costos recortará otros 1000 casos del total.

Recomendaciones estratégicas basadas en los datos presentados

Auditorías De Calidad y Estandarización de Guías de Tallas:

Como se mencionó anteriormente, un 62% de las devoluciones se derivan de la disconformidad con el producto, lo que se puede solucionar con:

- La realización de una auditoría a los proveedores de SKUs con mayores tasas de defectos.
- Implementación de un diseño de las guías de tallas en sitios web, que incluyan medidas exactas en centímetros y aseguren que la fotografía técnica y descripción del producto coincidan al 100% con las especificaciones mencionadas por el fabricante.

Reestructuración de la Política de Descuentos y Comunicación Preventiva

Realizar un incremento desde el 1% al 40% no reduce la tasa de devoluciones, pero destruye las ganancias por pedido en un 41%, lo que a su vez se lleva un margen de unos $90,000 en ganancias, esto se puede abarcar desde la gerencia con acciones como:

- Eliminar o replantear los descuentos altamente agresivos del 30% al 40%, ya que estos son los principales reductores de ganancias sin incrementar la retención real de los clientes.
- Realizar un seguimiento interactivo con el cliente post venta para ofrecer manuales de uso, y soporte proactivo para resolver dudas antes de que pase por la mente del usuario realizar la devolución en el rango estimado de los 16 días.

Optimización Logística y Ajuste de Políticas de Envío de Retorno

Los pedidos que han sido devueltos están costando cerca de $60,000 a la empresa, y dentro de estos, 1000 de esos pedidos han sido exclusivos del “cambio de opinión” por parte de los clientes, esto se puede remediar con:

- Exigencia de un estándar de empaque, cumplimientos de SLA y de cuidados a los paquetes a las empresas de mensajería, reduciendo esos 1300 casos que se acumulan entre paquetes con daños en tránsito y llegadas tardías.
- Modificación de los términos y condiciones, para que en las devoluciones que sean por “cambio de opinión” el cliente asuma el costo de envío de regreso.

Gestión Segmentada de Clientes y Contención de Reembolsos

Como se definió anteriormente, un 59% aproximado de los clientes que realizan devoluciones se encuentran insatisfechos, y solo un 14% del total se categorizan como tóxicos, ante estos casos, se puede realizar lo siguiente:

- Configurar un alertamiento en el CRM para que los usuarios que realicen más de 2 devoluciones sean “flaggeados” e investigados respectivamente en por qué realizaron dicha acción, ya que no podemos tampoco mutilar a clientes que hayan tenido razones válidas para devoluciones y los tratemos todos bajo un mismo espectro.
- Al procesar una nueva devolución en este ámbito de “insatisfechos/tóxicos” restringir el reembolso con efectivo o tarjeta, y ofrecerles a éstos crédito en la tienda, asegurando el flujo de capital operativo dentro de la empresa (lo cual ayuda a mitigar compras especulativas).